TC5061 - Experimentación y Seguimiento de Modelos con MLflow

Autor: Oscar Alfonso Valenzuela Muñoz | **Materia:** MLOps (Semana 4)
Repositorio GitHub: https://github.com/oscartrix/tec-mlops-2026.git

1. Comando de Ejecución

La ejecución del script de entrenamiento parametrizado se realiza directamente desde la terminal. Para reproducir la mejor configuración encontrada se ejecuta el siguiente comando:

```
python src/train.py --n-estimators 100 --max-depth 5 --min-samples-split 2
--min-samples-leaf 1 --random-state 42
```

Para ejecutar la batería completa de las cinco corridas comparativas de forma desatendida, se incluye el script de automatización:

```
bash run_experiments.sh
```

2. Comparación Sistemática de Experimentos

Se registraron cinco corridas bajo el experimento *Paddy_Yield_Random_Forest* en el servidor de MLflow Tracking, variando sistemáticamente la profundidad máxima, el número de estimadores y las restricciones de división en nodos y hojas. La tabla siguiente presenta los parámetros evaluados y las métricas obtenidas sobre el conjunto de prueba independiente (20% de los datos con semilla fija en 42):

Corrida	max_depth	n_estimators	min_split	min_leaf	RMSE (kg)	MAE (kg)	R^2
shallow_depth_5 (Mejor)	5	100	2	1	**910.49**	**654.73**	**0.9903**
regularized_split10_leaf4	None	200	10	4	931.82	673.95	0.9899
intermediate_depth_10_leaf_2	10	150	5	2	952.39	685.91	0.9894
deep_trees_depth_15_n250	15	250	2	1	965.75	693.32	0.9891
baseline_default	None	100	2	1	968.59	695.62	0.9890

3. Análisis de Resultados

Configuración con mejor desempeño: La corrida identificada como *shallow_depth_5* obtuvo el mejor resultado global entre todas las variantes evaluadas, registrando un RMSE de 910.49 kg, un MAE de 654.73 kg y un coeficiente de determinación R^2 de 0.9903. Al contrastarla con la línea base no restringida (RMSE de 968.59 kg y MAE de 695.62 kg), se aprecia una reducción del error cuadrático medio de 58.10 kg y de 40.89 kg en el error absoluto. Esto evidencia que fijar una cota superior a la profundidad previene la sobreespecialización del ensamble en fluctuaciones particulares del conjunto de entrenamiento.

Hiperparámetro más influyente: El hiperparámetro de mayor impacto sobre la capacidad predictiva fue la profundidad máxima del árbol (*max_depth*), seguido de la restricción del tamaño de nodo hoja (*min_samples_leaf*). Los árboles con profundidad libre (*max_depth=None*) o elevada (*max_depth=15*) tendieron a memorizar ruido local en las variables agronómicas continuas. En contraste, restringir la profundidad a 5 niveles o imponer un mínimo de 4 observaciones por hoja (*regularized_split10_leaf4*, RMSE 931.82 kg) aportó una regularización estructural decisiva. Asimismo, incrementar el número de árboles de 100 a 250 generó retornos marginales decrecientes y elevó el tiempo de cómputo sin mitigar el sobreajuste cuando la profundidad permaneció sin control.

Limitaciones observadas: En primer lugar, la partición aleatoria simple no modela posibles agrupaciones geoespaciales o temporales inherentes a los ciclos agrícolas del cultivo de arroz, lo que puede sobrestimar el desempeño en regiones no contempladas. En segundo lugar, la codificación por variables ficticias (One-Hot Encoding) aumentó la dimensionalidad a 63 columnas, incrementando la dispersión en las decisiones de corte de los árboles. Por último, aunque el coeficiente R^2 supera 0.98 debido a dependencias funcionales entre variables de entrada y rendimiento, la validez del modelo requiere corroboración en temporadas posteriores con condiciones climáticas atípicas.

Anexo: Evidencias de Seguimiento en MLflow

A continuación se presentan las capturas de pantalla obtenidas directamente desde la interfaz web de MLflow Tracking (alojada en http://127.0.0.1:5000), donde se comprueba el registro centralizado del experimento, las cinco corridas y los artefactos generados.

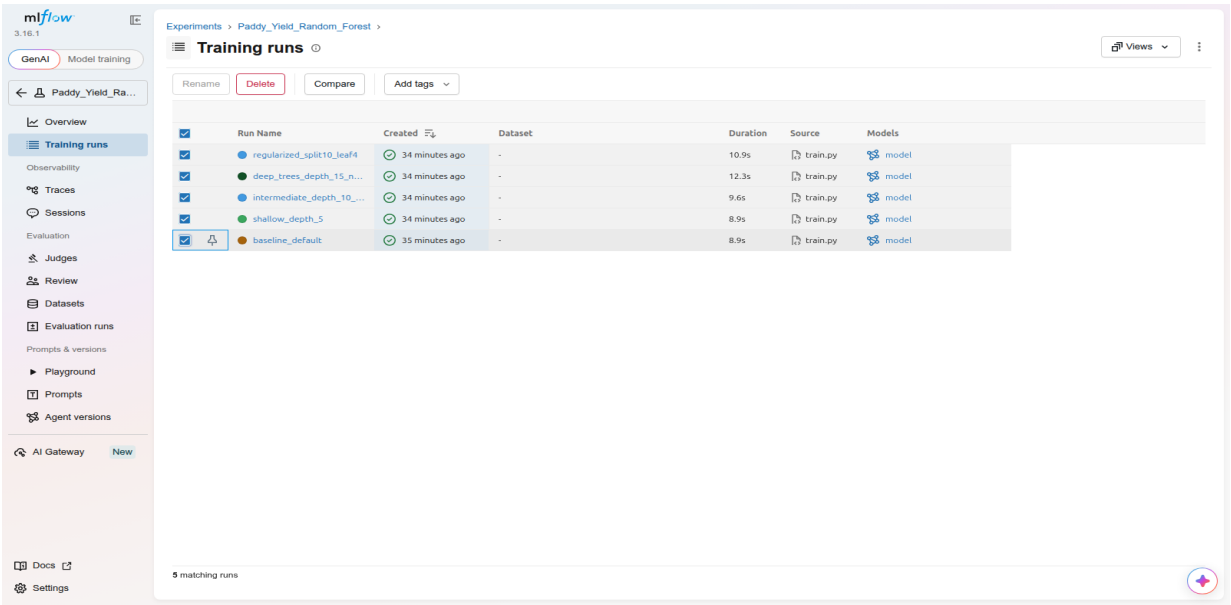


Figura 1. Tabla de corridas en MLflow con las cinco configuraciones registradas y seleccionadas para comparación.

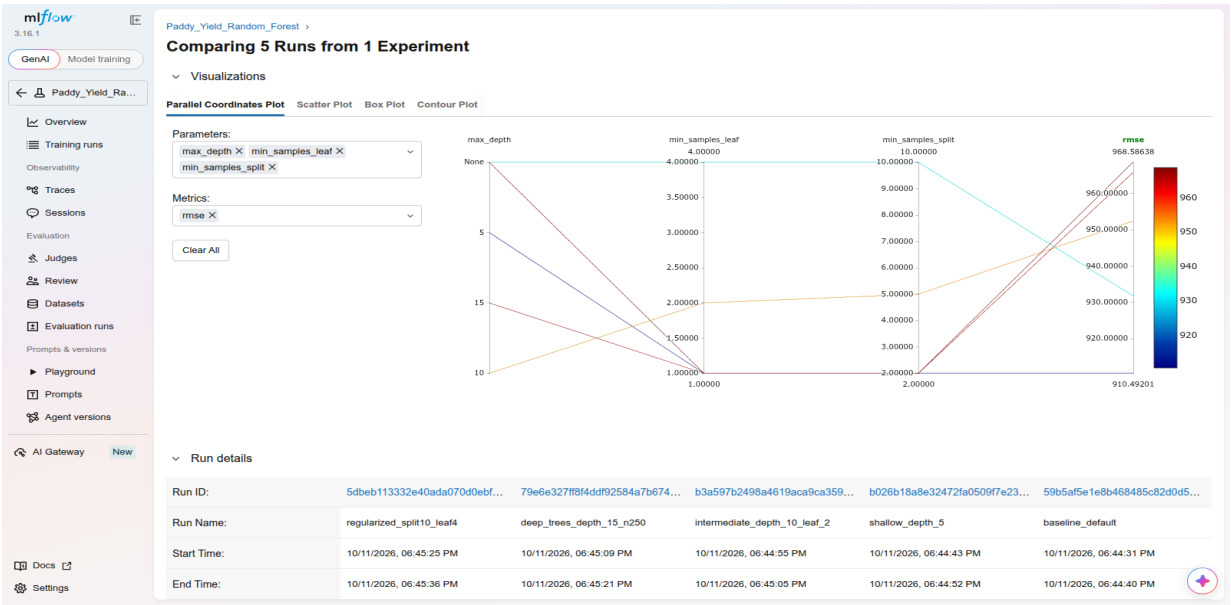


Figura 2. Vista de comparación de MLflow (Comparing 5 Runs) con gráfica de coordenadas paralelas y contraste de métricas.

Anexo: Detalle y Artefactos de la Corrida Ganadora

Se verificó el registro de artefactos dentro del almacén de MLflow, incluyendo gráficas de dispersión (valores reales vs. predichos), distribución de residuales, importancia de características, reporte JSON de métricas y el modelo empaquetado con firma de entrada y salida.



Figura 3. Explorador de artefactos en MLflow mostrando la previsualización directa de la gráfica de dispersión para shallow_depth_5.

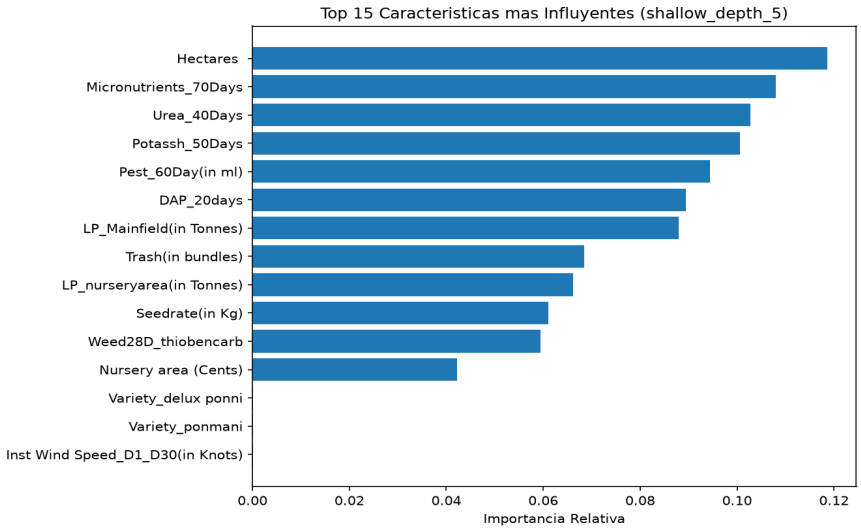


Figura 4. Gráfica de importancia de características registrada como artefacto en MLflow.